

# Clasificación basada en Naïve Bayes

- Familia de modelos basados en Bayes.
- Veremos Clasificador de Naive Bayes.
- También existen las Redes Bayesianas.

# Clasificación Basada en Naïve Bayes

- Modelo que busca **modelar la relación probabilística** entre atributos y clase.
- Modelo generativo, asume una distribución conjunta entre  $X$  e  $Y$ .
- Supuesto: atributos independientes dado la clase (**naïve assumption**).

# Clasificador Bayesiano

- Esquema probabilístico para resolver problemas de clasificación.

- Probabilidad condicional: 
$$P(C | A) = \frac{P(A, C)}{P(A)}$$

$$P(A | C) = \frac{P(A, C)}{P(C)}$$

- Teorema de Bayes: 
$$P(C | A) = \frac{P(A | C)P(C)}{P(A)}$$

# Ejemplo Teorema de Bayes

- Dado:
  - Un doctor sabe que la meningitis produce rigidez de cuello el 50% de las veces.
  - La probabilidad previa de que cualquier paciente tenga meningitis es  $1/50,000$ .
  - La probabilidad previa de que cualquier paciente tenga rigidez en el cuello es de  $1/20$ .
- ¿Si un paciente tiene el cuello rígido, cuál es la probabilidad de que tenga meningitis?

$$P(M | S) = \frac{P(S | M)P(M)}{P(S)} = \frac{0.5 \times 1/50000}{1/20} = 0.0002$$

# Clasificador Naïve Bayes

- Considerar cada atributo como variable condicionalmente independiente de la clase (eso es “naive”).
- Dado un record con atributos  $(A_1, A_2, \dots, A_n)$ .
  - La meta es predecir la clase  $C$ .
  - Específicamente queremos encontrar el  $C$  que maximice  $P(C | A_1, A_2, \dots, A_n)$ .
- ¿Podemos estimar  $P(C | A_1, A_2, \dots, A_n)$  directamente de los datos?

# Clasificador Naïve Bayes

- Aproximación
- Computar la probabilidad posterior  $P(C \mid A_1, A_2, \dots, A_n)$  para todos los valores de  $C$  usando el Teorema de Bayes.

$$P(C \mid A_1 A_2 \dots A_n) = \frac{P(A_1 A_2 \dots A_n \mid C) P(C)}{P(A_1 A_2 \dots A_n)}$$

- Elegir un valor de  $C$  que maximice  $P(C \mid A_1, A_2, \dots, A_n)$ .
- Equivalente a elegir un valor de  $C$  que maximice  $P(A_1, A_2, \dots, A_n \mid C) P(C)$ .
- Esto es porque el numerador  $P(A_1 A_2 \dots A_n)$  es constante para todas las clases.

# Clasificador Naïve Bayes

- Asume independencia entre los atributos  $A_i$  cuando la clase está dada (independencia condicional):
  - $P(A_1, A_2, \dots, A_n | C) = P(A_1 | C) P(A_2 | C) \dots P(A_n | C)$ .
  - Se puede estimar  $P(A_i | C)$  para todos los  $A_i$  y  $C$ .
  - Un punto nuevo  $A$ , se clasifica como  $C_j$  si  $P(C_j) \prod P(A_i | C_j)$  es máxima (en comparación con otros valores de  $C$ ).

# ¿Cómo estimar probabilidades a partir de los datos?

<i>Tid</i>	Refund	Marital Status	Taxable Income	Evade
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

- Clase:  $P(C_k) = \frac{\text{count}(C_k)}{N}$

- e.g.,  $P(\text{No}) = 7/10$ ,  
 $P(\text{Yes}) = 3/10$

- Para atributos discretos:

$$P(A_i = b|C_k) = \frac{\text{count}(A_{ik} = b)}{\text{count}(C_k)}$$

- donde  $\text{count}(A_{ik} = b)$  es el número de instancias que tiene el valor  $b$  para el atributo  $A_i$  y que pertenecen a la clase  $C_k$

- Ejemplos:

- $P(\text{Status} = \text{Married} | \text{No}) = 4/7$   
 $P(\text{Refund} = \text{Yes} | \text{Yes}) = 0$



# Laplace Smoothing

- $P(C \mid A_1, A_2, \dots, A_n)$  se puede ir a cero cuando  $|A_{ik}=b| = 0$ , osea cuando para alguna clase  $C_k$  no hay ningún ejemplo con  $A_i=b$ .
- En ese caso Naive Bayes le asignaría probabilidad cero a la clase  $C_k$  a cualquier ejemplo con  $|A_{ik}=b| = 0$ , ignorando el valor de los otros atributos (acuérdense que las probabilidades se multiplican).
- Eso no es bueno para la generalización del modelo.
- Laplace Smoothing: soluciona el problema sumándole 1 a todos los conteos para que ninguna probabilidad quede en cero:

$$P(A_i = b|C_k) = \frac{\text{count}(A_{ik} = b) + 1}{\text{count}(C_K) + \text{values}(A_i)}$$

- Donde  $\text{values}(A_i)$  es la cantidad de categorías del atributo  $A_i$ .
- Con Laplace smoothing  $P(\text{Status} = \text{Married}|\text{No}) = (4+1)/(7+3)$

# Atributos Numéricos

- ¿Cómo calculamos  $P(A_{ik}=b|C_k)$  cuando el atributo  $A_i$  es numérico (ej: Taxable income) ?
- Una opción es discretizar el atributo y proceder de la forma anterior.
- Otra solución es asumir que el atributo sigue una distribución Gaussiana y estimar los parámetros de la función de densidad:

$$P(A_i = b|C_k) = \frac{1}{\sqrt{2\pi}\sigma_{ik}} \exp -\frac{(b-\mu_{ik})^2}{2\sigma_{ik}^2}$$

- Aquí  $\mu_{ik}$  y  $\sigma_{ik}$  se estiman como la media muestral y la desviación estándar de los ejemplos del atributo  $A_i$  cuando la clase es  $C_k$
- Sea  $A_i$  = Taxable income y  $C_k$ =No,  $\mu_{ik}$  = mean(125,100,70,120,60,220,75) =110 y  $\sigma_{ik}$ =sd(125,100,70,120,60,220,75)=54.5

$P(\text{Taxable Income} = 130 | \text{No}) = \text{dnorm}(x=130, \text{mean}=110, \text{sd}=54.5) = 0.006843379$

# Naïve Bayes (Resumen)

- Es robusto ante puntos de ruido aislados.
- Maneja valores faltantes ignorando la instancia durante los cálculos de estimación de probabilidades.
- Robusto a atributos irrelevantes (afectan de igual manera a todas las clases).
- El supuesto de independencia entre atributos puede no ser cierto en todos los casos.
- Las redes Bayesianas o los modelos gráficos dirigidos permiten hacer modelos probabilísticos con supuestos de independencia menos restrictivos.