

# Probabilidad

¿Cuál es la probabilidad de aprobar Minería de Datos?

¿Cuál es la probabilidad de no encontrarme un trancon cuando voy a clase?

Todos los días nos hacemos preguntas sobre probabilidad e incluso los que hayáis visto poco de la materia en cursos anteriores, tenéis una idea intuitiva lo suficientemente correcta para lo que necesitamos de ella en este curso.


# Nociones de probabilidad

- **Frecuentista** (objetiva): Probabilidad de un suceso es la frecuencia relativa (%) de veces que ocurriría el **suceso** al realizar un experimento repetidas veces.

CLASIFICACION OMS

		Frecuencia	Porcentaje
Válidos	NORMAL	469	46,9%
	OSTEOPENIA	467	46,7%
	OSTEOPOROSIS	64	6,4%
	Total	1000	100,0

CLASIFICACION OMS








- **Subjetiva** (bayesiana): Grado de certeza que se posee sobre un **suceso**. Es personal.

En ambos tipos de definiciones aparece el concepto de **suceso**.  
Vamos a ver qué son y algunas operaciones que se pueden realizar con sucesos.

# Sucesos


- Cuando se realiza un experimento aleatorio diversos resultados son posibles. El conjunto de todos los resultados posibles se llama **espacio muestral** (E).
- Se llama **suceso** a un subconjunto de dichos resultados.
- Se llama **suceso contrario** (complementario) de un suceso A,  $A'$ , al formado por los elementos que no están en A
- Se llama **suceso unión** de A y B,  $A \cup B$ , al formado por los resultados experimentales que están en A o en B (incluyendo los que están en ambos).
- Se llama **suceso intersección** de A y B,  $A \cap B$  o simplemente  $AB$ , al formado por los elementos que están en A y B



# Definición de probabilidad

- Se llama **probabilidad** a cualquier función,  $P$ , que asigna a cada suceso  $A$  un valor numérico  $P(A)$ , verificando las siguientes reglas (axiomas)


- $P(E)=1$



- $0 \leq P(A) \leq 1$


- $P(A \cup B) = P(A) + P(B)$  si  $A \cap B = \emptyset$

- $\emptyset$  es el conjunto vacío.




- Podéis imaginar la probabilidad de un subconjunto como el tamaño relativo con respecto al total (suceso seguro)


# EJEMPLOS



$$\begin{aligned} P(A) &=? \\ P(B) &=? \\ P(A \cup B) &=? \\ P(AB) &=? \\ P(A') &=? \\ P(B') &=? \end{aligned}$$



$$\begin{aligned} P(A) &=? \\ P(B) &=? \\ P(A \cup B) &=? \\ P(AB) &=? \\ P(A') &=? \\ P(B') &=? \end{aligned}$$




$$\begin{aligned} P(A) &=? \\ P(B) &=? \\ P(A \cup B) &=? \\ P(AB) &=? \\ P(A') &=? \\ P(B') &=? \end{aligned}$$

# Probabilidad condicionada

- Se llama **probabilidad de A condicionada a B**, o **probabilidad de A sabiendo que pasa B**:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$


“tamaño”  
de uno  
respecto al  
otro



## ■ Error frecuentíiiiiisimo:

- No confundir probabilidad condicionada con intersección.
- En ambos medimos efectivamente la intersección, **pero...**
  - En  $P(A \cap B)$  con respecto a  $P(E)=1$
  - En  $P(A|B)$  con respecto a  $P(B)$

# EJEMPLOS



$$P(A) = 3/9 = 1/3$$

$$P(B) = 5/9$$

$$P(A \cup B) = 6/9 = 2/3$$


$$P(AB) = 2/9$$

$$P(A') = 6/9 = 2/3$$

$$P(B') = 4/9$$

$$P(A|B) = ?$$

$$P(B|A) = ?$$



$$P(A) = 3/9 = 1/3$$

$$P(B) = 2/9$$

$$P(A \cup B) = 5/9$$


$$P(AB) = 0$$

$$P(A') = 6/9 = 2/3$$

$$P(B') = 7/9$$

$$P(A|B) = ?$$

$$P(B|A) = ?$$



$$P(A) = 3/9 = 1/3$$

$$P(B) = 2/9$$

$$P(A \cup B) = 3/9 = 1/3$$

$$P(AB) = 2/9$$


$$P(A') = 6/9 = 2/3$$

$$P(B') = 7/9$$

$$P(A|B) = ?$$

$$P(B|A) = ?$$


# Intuir la probabilidad condicionada



$$\begin{aligned}P(A) &= 0,25 \\P(B) &= 0,10 \\P(A \cap B) &= 0,10\end{aligned}$$

¿Probabilidad de A sabiendo que ha pasado B?

$$P(A|B)=1$$




$$\begin{aligned}P(A) &= 0,25 \\P(B) &= 0,10 \\P(A \cap B) &= 0,08\end{aligned}$$

$$P(A|B)=0,8$$




# Intuir la probabilidad condicionada



$$\begin{aligned}P(A) &= 0,25 \\P(B) &= 0,10 \\P(A \cap B) &= 0,005\end{aligned}$$

¿Probabilidad de A sabiendo que ha pasado B?

$$P(A|B)=0,05$$



$$\begin{aligned}P(A) &= 0,25 \\P(B) &= 0,10 \\P(A \cap B) &= 0\end{aligned}$$

$$P(A|B)=0$$

# Algunas reglas de cálculo prácticas

- Cualquier problema de probabilidad puede resolverse en teoría mediante aplicación de los axiomas. Sin embargo, **es más cómodo conocer algunas reglas de cálculo:**

- $P(A') = 1 - P(A)$

- $P(A \cup B) = P(A) + P(B) - P(AB)$

- $P(AB) = P(A) P(B|A)$

$$= P(B) P(A|B)$$

- Prob. de que pasen A y B es la prob. de A y que también pase B sabiendo que pasó A.

# Ejemplo (I)

Recuento		MENOPAUSIA		Total
		NO	SI	
CLASIFICACION OMS	NORMAL	189	280	469
	OSTEOPENIA	108	359	467
	OSTEOPOROSIS	6	58	64
Total		303	697	1000

- Se ha repetido en 1000 ocasiones el experimento de elegir a una mujer de una población muy grande. El resultado está en la tabla.
  - ¿Cuál es la probabilidad de que una mujer tenga osteoporosis?
    - $P(\text{Osteoporosis}) = \frac{64}{1000} = 0,064 = 6,4\%$ 
      - Noción frecuentista de probabilidad
  - ¿Cuál es la probabilidad de que una mujer no tenga osteoporosis?
    - $P(\text{No Osteoporosis}) = 1 - P(\text{Osteoporsis}) = 1 - \frac{64}{1000} = 0,936 = 93,6\%$

## Ejemplo (II)

Recuento		MENOPAUSIA		Total
		NO	SI	
CLASIFICACION OMS	NORMAL	189	280	469
	OSTEOPENIA	108	359	467
	OSTEOPOROSIS	6	58	64
Total		303	697	1000

- ¿Probabilidad de tener osteopenia u osteoporosis?
  - $P(\text{Osteopenia} \cup \text{Osteoporosis}) = P(\text{Osteopenia}) + P(\text{Osteoporosis}) - P(\text{Osteopenia} \cap \text{Osteoporosis}) = \frac{467}{1000} + \frac{64}{1000} = 0,531$ 
    - Son sucesos disjuntos
    - $\text{Osteopenia} \cap \text{Osteoporosis} = \emptyset$
- ¿Probabilidad de tener osteoporosis o menopausia?
  - $P(\text{Osteoporosis} \cup \text{Menopausia}) = P(\text{Osteoporosis}) + P(\text{Menopausia}) - P(\text{Osteoporosis} \cap \text{Menopausia}) = \frac{64}{1000} + \frac{697}{1000} - \frac{58}{1000} = 0,703$ 
    - No son sucesos disjuntos
- ¿Probabilidad de una mujer normal?
  - $P(\text{Normal}) = \frac{469}{1000} = 0,469$
  - $P(\text{Normal}) = 1 - P(\text{Normal}') = 1 - P(\text{Osteopenia} \cup \text{Osteoporosis}) = 1 - 0,531 = 0,469$

## Ejemplo (III)

Recuento		MENOPAUSIA		Total
		NO	SI	
CLASIFICACION	NORMAL	189	280	469
OMS	OSTEOPENIA	108	359	467
	OSTEOPOROSIS	6	58	64
Total		303	697	1000

- Si es menopáusica... ¿probabilidad de osteoporosis?

- $P(\text{Osteoporosis} | \text{Menopausia}) = 58/697 = 0,098$

- ¿Probabilidad de menopausia y osteoporosis?

- $P(\text{Menop} \cap \text{Osteoporosis}) = 58/1000 = 0,058$

- Otra forma:

$$\begin{aligned}
 P(\text{Menop} \cap \text{Osteoporosis}) &= P(\text{Menop}) \times P(\text{Osteoporosis} | \text{Menop}) = \\
 &= \frac{\cancel{697}}{1000} \times \frac{58}{\cancel{697}} = 58/1000 = 0,058
 \end{aligned}$$

## Ejemplo (III)

Recuento

		MENOPAUSIA		Total
		NO	SI	
CLASIFICACION	NORMAL	189	280	469
OMS	OSTEOPENIA	108	359	467
	OSTEOPOROSIS	6	58	64
Total		303	697	1000

- Si tiene osteoporosis... ¿probabilidad de menopausia?
  - $P(\text{Menopausia} | \text{Osteoporosis}) = \frac{58}{64} = 0,906$
- ¿Probabilidad de menopausia y no osteoporosis?
  - $P(\text{Menop} \cap \text{No Osteoporosis}) = \frac{639}{1000} = 0,639$
- Si tiene no tiene osteoporosis... ¿probabilidad de no menopausia?
  - $P(\text{No Menopausia} | \text{No Osteoporosis}) = \frac{297}{936} = 0,317$

# Independencia de sucesos

- Dos sucesos son independientes si el que ocurra uno, no añade información sobre el otro.

- A es independiente de B

$$\Leftrightarrow P(A|B) = P(A)$$

$$\Leftrightarrow P(AB) = P(A) P(B)$$

## Ejemplo (IV)

Recuento		MENOPAUSIA		Total
		NO	SI	
CLASIFICACION	NORMAL	189	280	469
OMS	OSTEOPENIA	108	359	467
	OSTEOPOROSIS	6	58	64
Total		303	697	1000

### • ¿Son independientes menopausia y osteoporosis?

#### • Una forma de hacerlo

- $P(\text{Osteoporosis}) = 64/1000 = 0,064$

- $P(\text{Osteoporosis} | \text{Menopausia}) = 58/697 = 0,098$

- La probabilidad de tener osteoporosis es mayor si ha pasado la menopausia. Añade información extra. ¡No son independientes!

#### • ¿Otra forma?

- $P(\text{Menop} \cap \text{Osteoporosis}) = 58/1000 = 0,058$

- $P(\text{Menop}) P(\text{Osteoporosis}) = (697/1000) \times (64/1000) = 0,045$

- La probabilidad de la intersección no es el producto de probabilidades. No son independientes.





# Sistema exhaustivo y excluyente de sucesos

Son una colección de sucesos


$A_1, A_2, A_3, A_4 \dots$

Tales que la unión de todos ellos forman el espacio muestral, y sus intersecciones son disjuntas.

¿Recordar cómo formar intervalos en tablas de frecuencias?




# Divide y vencerás



Todo suceso B, puede ser **descompuesto** en componentes de dicho sistema.

$$B = (B \cap A_1) \cup (B \cap A_2) \cup (B \cap A_3) \cup (B \cap A_4)$$




Nos permite descomponer el problema B en **subproblemas más simples**. Funciona.

# Teorema de la probabilidad total

Si conocemos la probabilidad de B en cada uno de los componentes de un sistema exhaustivo y excluyente de sucesos, entonces...

... podemos calcular la probabilidad de B.



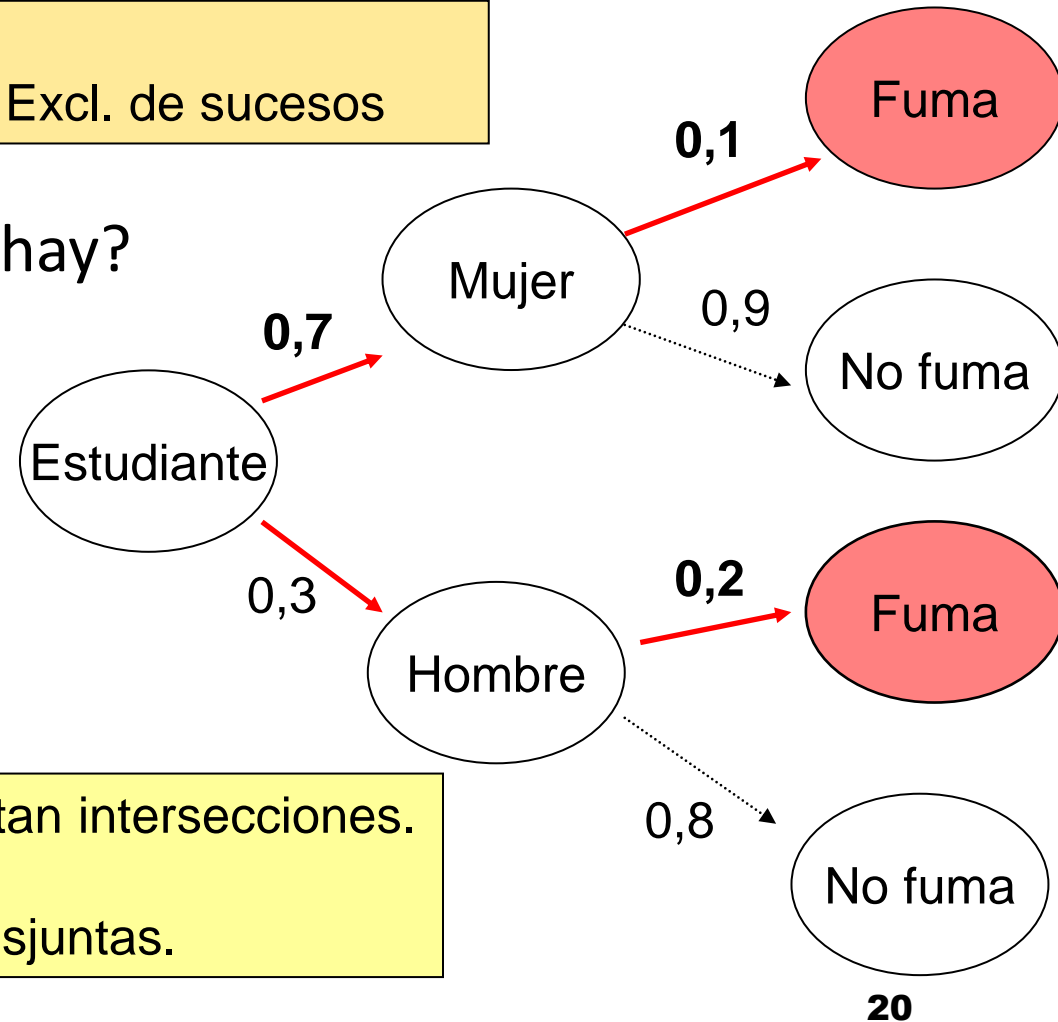
**Ejemplo (I):** En este aula el 70% de los alumnos son mujeres. De ellas el 10% son fumadoras. De los hombres, son fumadores el 20%.

**T. Prob. Total.**

Hombres y mujeres forman un sist. Exh. Excl. de sucesos

• ¿Qué porcentaje de fumadores hay?

$$\begin{aligned} & \bullet P(F) = P(M \cap F) + P(H \cap F) \\ & = P(M)P(F|M) + P(H)P(F|H) \\ & = 0,7 \times 0,1 + 0,3 \times 0,2 \\ & = 0,13 = 13\% \end{aligned}$$



• Los caminos a través de nodos representan intersecciones.

• Las bifurcaciones representan uniones disjuntas.

**Ejemplo (II):** En un centro hay dos quirófanos. El 1º se usa el 75% de veces para operar. En el 1º la frec. de infección es del 5% y en el 2º del 10%.

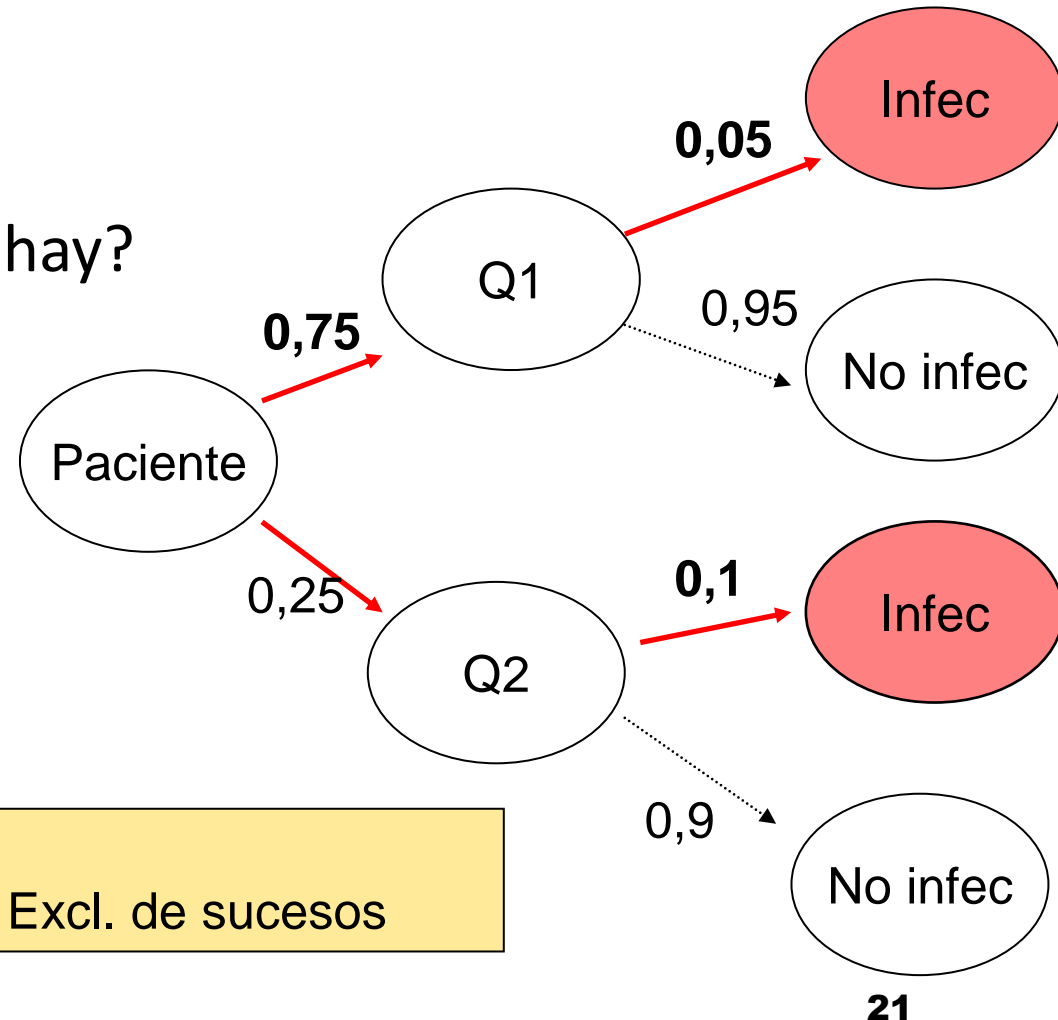
- ¿Qué probabilidad de infección hay?

- $P(I) = P(Q1 \cap I) + P(Q2 \cap I)$

- $= P(Q1)P(I|Q1) + P(Q2)P(I|Q2)$

- $= 0,75 \times 0,05 + 0,25 \times 0,1$

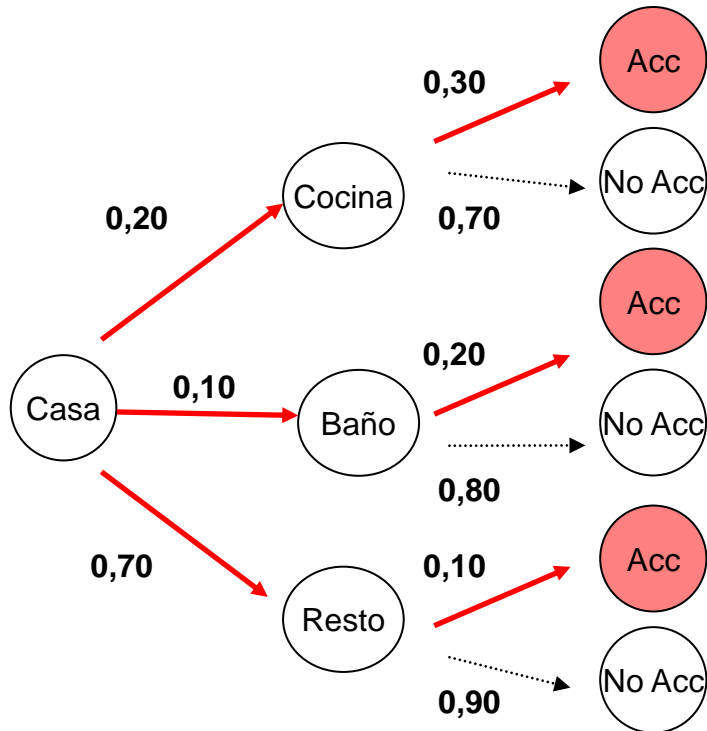
- $= 0,0625$



**T. Prob. Total.**


Los dos quirófanos forman un sist. Exh. Excl. de sucesos

**Ejemplo (III):** El 20% del tiempo que se está en una casa transcurre en la cocina, el 10% en el baño y el resto entre el salón y el dormitorio. Por otro lado la probabilidad de tener un accidente doméstico estando en la cocina es de 0,30 de tenerlo estando en el baño es de 0,20 y de tenerlo fuera de ambos de 0,10. ¿Cuál es la probabilidad de tener un accidente doméstico?



$$\begin{aligned} P(A) &= P(A \cap C) + P(A \cap B) + P(A \cap R) = \\ &= P(C)P(A|C) + P(B)P(A|B) + P(R)P(A|R) \\ &= 0,2 \times 0,3 + 0,1 \times 0,2 + 0,7 \times 0,1 = 0,15 = \\ &15\% \end{aligned}$$

# Teorema de Bayes



Si conocemos la probabilidad de  $B$  en cada uno de los componentes de un sistema exhaustivo y excluyente de sucesos, entonces...

...si ocurre  $B$ , podemos calcular la probabilidad (*a posteriori*) de ocurrencia de cada  $A_i$ .

$$P(A_i | B) = \frac{P(B | A_i) P(A_i)}{P(B)}$$

donde  $P(B)$  se puede calcular usando el teorema de la probabilidad total:

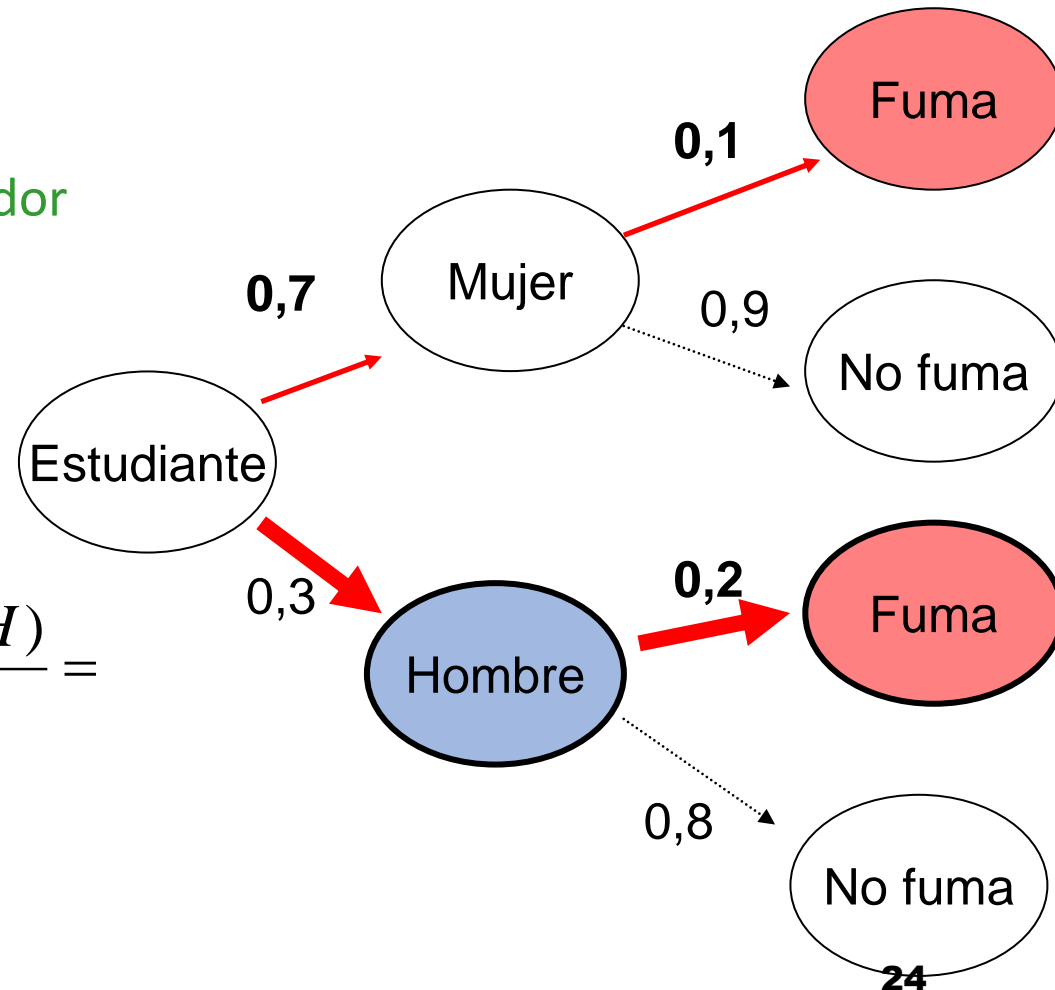
$$P(B) = P(B \cap A_1) + P(B \cap A_2) + P(B \cap A_3) + P(B \cap A_4)$$

$$= P(B | A_1) P(A_1) + P(B | A_2) P(A_2) + \dots$$

**Ejemplo (IV):** En este aula el 70% de los alumnos son mujeres. De ellas el 10% son fumadoras. De los varones, son fumadores el 20%.

- ¿Qué porcentaje de fumadores hay?
  - $P(F) = 0,7 \times 0,1 + 0,3 \times 0,2 = 0,13$
  - (Resuelto antes)
- Se elije a un individuo al azar y es... fumador  
¿Probabilidad de que sea un hombre?

$$\begin{aligned} P(H | F) &= \frac{P(H \cap F)}{P(F)} = \frac{P(H) \cdot P(F | H)}{P(F)} = \\ &= \frac{0,3 \times 0,2}{0,13} = 0,46 \end{aligned}$$

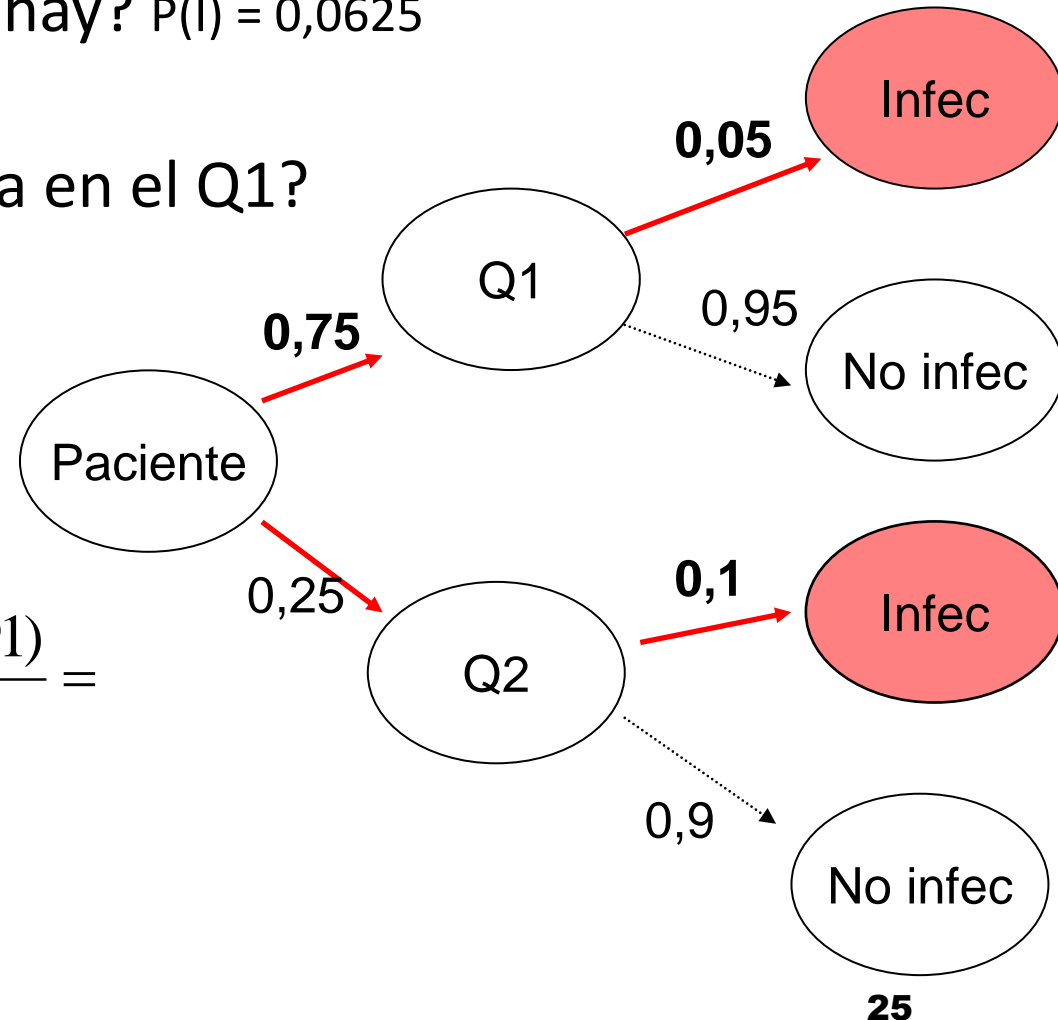




**Ejemplo (V):** En un centro hay dos quirófanos. El 1º se usa el 75% de veces para operar. En el 1º la frec. de infección es del 5% y en el 2º del 10%.

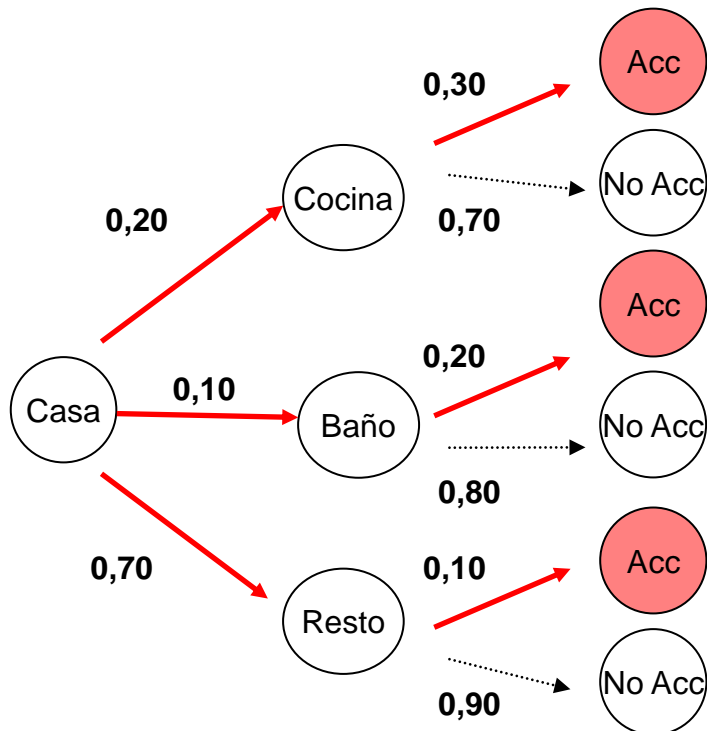
- ¿Qué probabilidad de infección hay?  $P(I) = 0,0625$
- Se ha producido una infección.

¿Qué probabilidad hay de que sea en el Q1?



$$P(Q1 | I) = \frac{P(Q1 \cap I)}{P(I)} = \frac{P(Q1) \cdot P(I | Q1)}{P(I)} =$$
$$= \frac{0,75 \times 0,05}{0,0625} = 0,6$$

**Ejemplo (VI):** El 20% del tiempo que se está en una casa transcurre en la cocina, el 10% en el baño y el resto entre el salón y el dormitorio. Por otro lado la probabilidad de tener un accidente doméstico estando en la cocina es de 0,30 de tenerlo estando en el baño es de 0,20 y de tenerlo fuera de ambos de 0,10. Se ha producido un accidente, ¿cuál es la probabilidad de que haya sido en la cocina?



$P(A) = 0,15$  (ya calculado)


$$P(C | A) = \frac{P(C \cap A)}{P(A)} = \frac{P(C) \cdot P(A | C)}{P(A)} =$$
$$= \frac{0,20 \times 0,30}{0,15} = 0,4$$

# Ejemplo de prueba diagnósticas: Diabetes

- Los carbohidratos ingeridos terminan como glucosa en la sangre. El exceso se transforma en glucógeno y se almacena en hígado y músculos. Este se transforma entre comidas de nuevo en glucosa según necesidades.
- La principal hormona que regula su concentración es la insulina. La diabetes provoca su deficiencia o bien la insensibilidad del organismo a su presencia. Es una enfermedad muy común que afecta al 2% de la población (**prevalencia**)
- Una prueba común para diagnosticar la diabetes, consiste en medir el nivel de glucosa. En individuos sanos suele variar entre 64 y 110mg/dL.
  - El cambio de color de un indicador al contacto con la orina suele usarse como indicador (**resultado del test positivo**)
- Valores por encima de 110 mg/dL se asocian con un posible estado pre-diabético.
  - Pero no es seguro. Otras causas podrían ser: hipertiroidismo, cancer de páncreas, pancreatitis, atracón reciente de comida...
- Supongamos que los enfermos de diabetes, tienen un valor medio de 126mg/dL.

# Funcionamiento de la prueba diagnóstica de glucemia

- **Valor límite: 110mg/dL**
  - Superior: test positivo.
  - Inferior: test negativo.





## Probabilidad de acierto:

- Para enfermos
  - Verdadero positivo (sensibilidad)
- Para sanos
  - Verdadero negativo (especificidad)

## Probabilidad de error

- Para enfermos
  - Falso -
- Para sanos
  - Falso +

¿Cómo

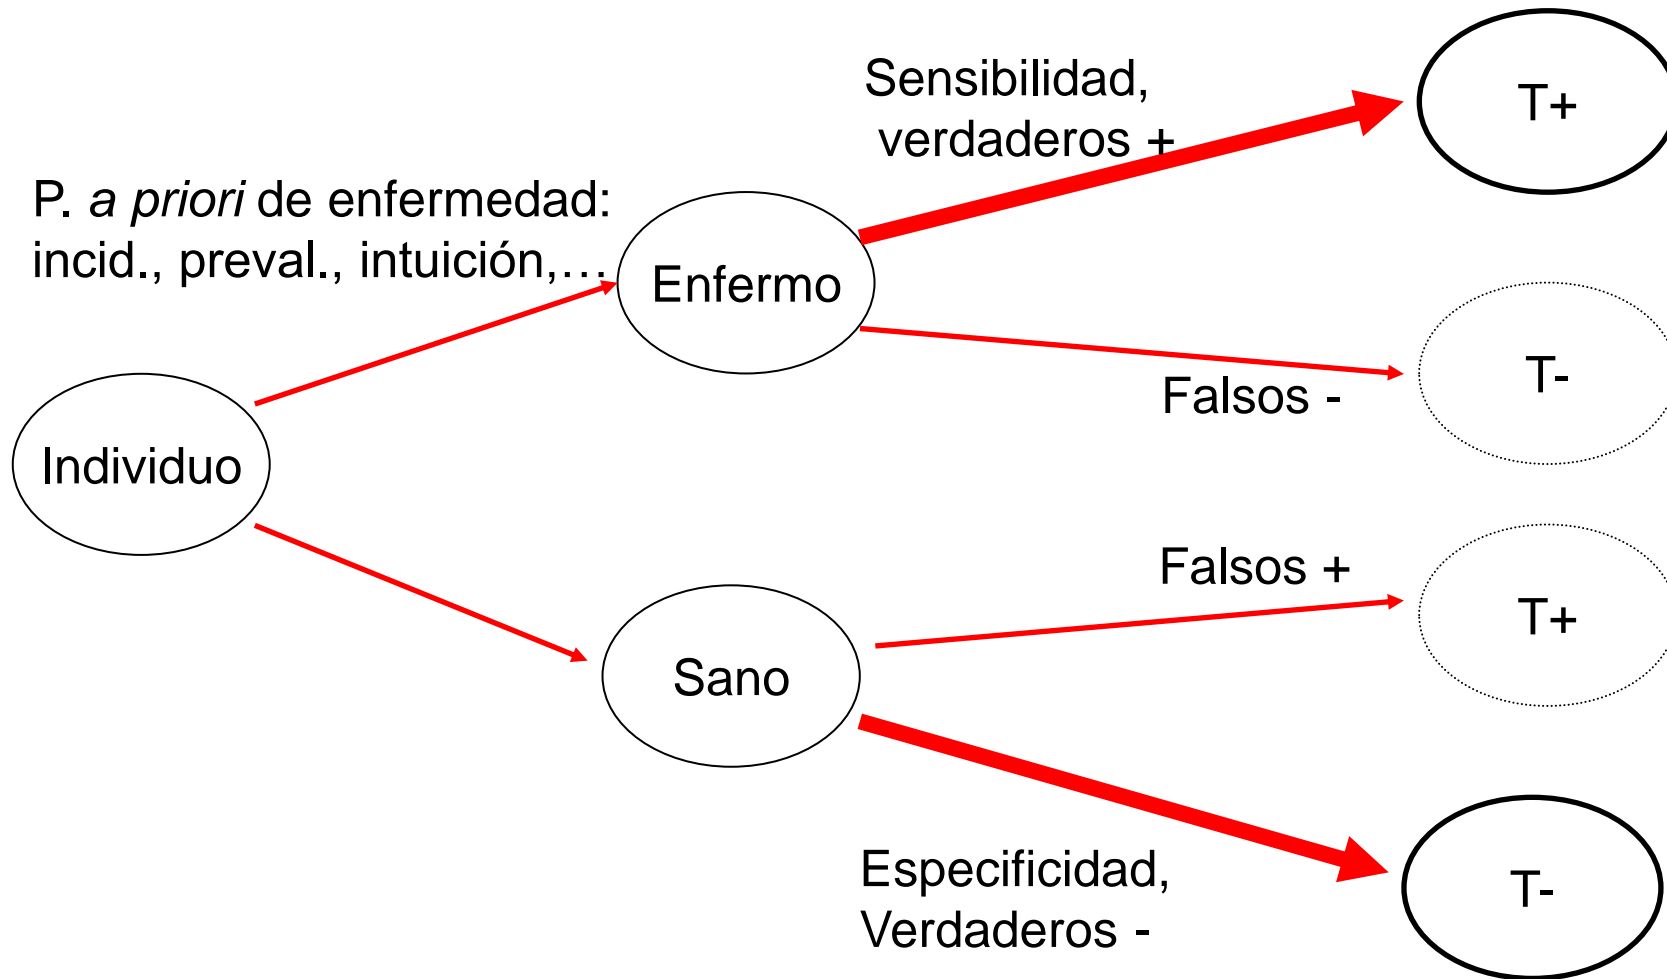


No es simple. **No es posible aumentar sensibilidad y especificidad al mismo tiempo.** Hay que elegir una solución de compromiso: Aceptable sensibilidad y especificidad.

Una **prueba diagnóstica** ayuda a mejorar una estimación de la probabilidad de que un individuo presente una enfermedad.

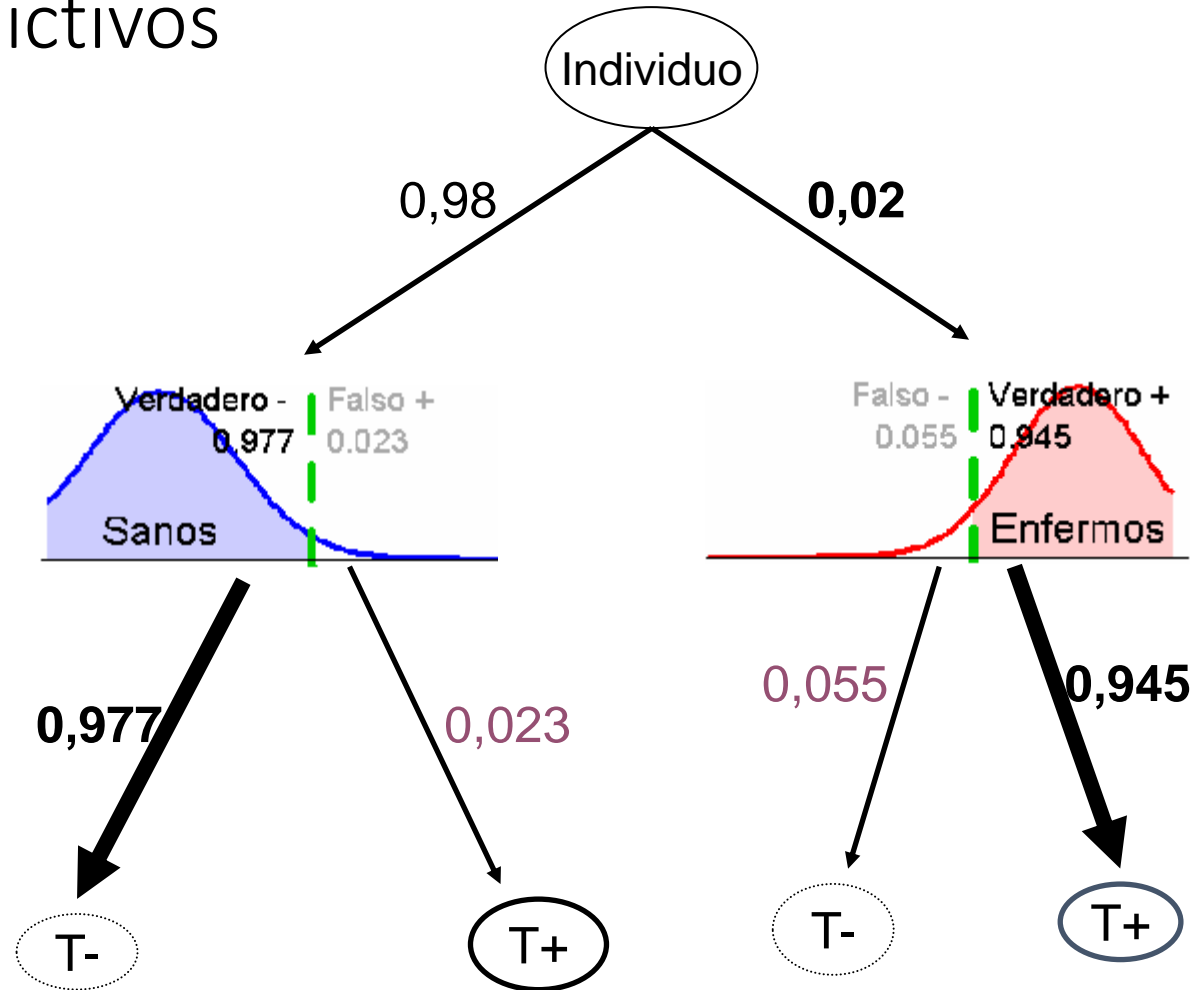
- En principio tenemos una **idea subjetiva** de  $P(\text{Enfermo})$ . Nos ayudamos de...
  - **Incidencia**: Porcentaje de nuevos casos de la enfermedad en la población.
  - **Prevalencia**: Porcentaje de la población que presenta una enfermedad.
- Para confirmar la sospecha, usamos una prueba diagnóstica. Ha sido evaluada con anterioridad sobre dos grupos de individuos: sanos y enfermos. Así **de modo frecuentista** se ha estimado:
  - $P(+ \mid \text{Enfermo}) = \text{Sensibilidad}$  (verdaderos +) = Tasa de acierto sobre enfermos.
  - $P(- \mid \text{Sano}) = \text{Especificidad}$  (verdaderos -) = Tasa de acierto sobre sanos.
- A partir de lo anterior y usando el **teorema de Bayes**, podemos calcular las probabilidades *a posteriori* (en función de los resultados del test):  
**Índices predictivos**
  - $P(\text{Enfermo} \mid +) = \text{Índice predictivo positivo}$
  - $P(\text{Sano} \mid -) = \text{Índice predictivo negativo}$

# Pruebas diagnósticas: aplicación T. Bayes.



# Ejemplo: Índices predictivos

- La diabetes afecta al 2% de los individuos.
- La presencia de glucosuria se usa como indicador de diabetes.
- Su sensibilidad es de 0,945.
- La especificidad es de 0,977.
- Calcular los índices predictivos.



$$P(\text{Sano} | T-) = \frac{P(\text{Sano} \cap T-)}{P(T-)} = \frac{P(\text{Sano})P(T- | \text{Sano})}{P(\text{Sano})P(T- | \text{Sano}) + P(\text{Enf})P(T- | \text{Enf})}$$

$$= \frac{0,98 \cdot 0,977}{0,98 \cdot 0,977 + 0,02 \cdot 0,055} = 0,999$$

$$P(\text{Enf} | T+) = \frac{P(\text{Enf} \cap T+)}{P(T+)} = \frac{P(\text{Enf})P(T+ | \text{Enf})}{P(\text{Sano})P(T+ | \text{Sano}) + P(\text{Enf})P(T+ | \text{Enf})}$$

$$= \frac{0,02 \cdot 0,945}{0,02 \cdot 0,945 + 0,98 \cdot 0,023} = 0,456$$



# Observaciones

- En el ejemplo anterior, al llegar un individuo a la consulta tenemos una idea *a priori* sobre la probabilidad de que tenga una enfermedad.
- A continuación se le pasa una *prueba diagnóstica* que nos aportará nueva información: Presenta glucosuria o no.
- En función del resultado tenemos una nueva idea (*a posteriori*) sobre la probabilidad de que esté enfermo.
  - Nuestra opinión a priori ha sido modificada por el resultado de un experimento.



- ¿Qué probabilidad tengo de estar enfermo?

- En principio un 2%. Le haremos unas pruebas.



- Presenta glucosuria. La probabilidad ahora es del 45,6%.